

一、安装及配置Ollama

1. 下载ollama
 2. 配置Ollama模型路径
 3. 下载ollama模型
 4. 启动模型成功
- ollama相关语句

二、使用docker仅安装Open-webui

1. docker desktop安装
2. 打开Hyper-V功能（没打开的话）
3. 下载open-webui镜像并启动容器
4. 确定运行
5. 注册
6. 离线部署（暂时没有尝试）

三、使用AnythingLLM搭建本地知识库

配置

1. 选择大模型（ollama）
2. 选择文本嵌入模型和向量数据库（默认）
3. 创建工作区并嵌入文档
4. 选择对话模式

其他

1. 本地nvm配置
2. 相关知识（不一定对，引用的）
3. 参考教程

一、安装及配置Ollama


1. 下载ollama

[Ollama](#)

下载完成后本地cmd输入 `ollama -v`，有版本回复代表下载成功

2. 配置Ollama模型路径

配置环境变量OLLAMA_MODELS，设置为指定的路径，因为我下载完成后环境变量中没有这一项，所以我是新增了环境变量，如下图：




3. 下载ollama模型

[Ollama Search](#)


在上述网址中寻找想要部署到本地的大模型，点击大模型名称进入模型主页，右上角有下载代码，例如：

```
ollama run gemma3
ollama run llama3:8b
ollama run deepseek-r1:7b
```



4. 启动模型成功

访问<http://127.0.0.1:11434/>，出现Ollama is running代表启动成功



ollama相关语句

```
ollama list #查看现有模型列表
ollama run 模型名称 #本地部署模型
ollama create 模型名称 -f .\Modelfile #根据配置文件Modelfile创建本地模型
```

二、使用docker仅安装Open-webui

1.docker desktop安装

这一步可能有错误，比如说安装时wsl报错

(Docker Desktop - WSL update failed,安装ubuntu, 安装适用于 Linux 的 Windows 子系统)

```
wsl --update #更新 windows 子系统 (WSL)
wsl --list --online #查看微软官方提供的子系统
wsl --install -d ubuntu #下载ubuntu
```

2.打开Hyper-V功能（没打开的话）

打开“控制面板->程序->启用或关闭Windows功能”→重启电脑后安装成功→Windows工具中可以看到Hyper-V已安装成功。

3.下载open-webui镜像并启动容器

```
docker run -d -p 3000:8080 --add-host=host.docker.internal:host-gateway -v open-webui:/app/backend/data --name open-webui --restart always ghcr.io/open-webui/open-webui:main
```

```
C:\Users\60578>docker run -d -p 3000:8080 --add-host=host.docker.internal:host-gateway -v open-webui:/app/backend/data -
-name open-webui --restart always ghcr.io/open-webui/open-webui:main
Unable to find image 'ghcr.io/open-webui/open-webui:main' locally
main: Pulling from open-webui/open-webui
b0a0cf830b12: Pull complete
72914424168c: Pull complete
d12a047f1c7e: Pull complete
ab33f1a2f662: Pull complete
94510a1366bc: Pull complete
8465800d2a48: Pull complete
40d545a2a21c: Pull complete
fa8f4b64ef22: Pull complete
eb1c407d6387: Pull complete
8717c66a142d: Pull complete
8a5bec779340: Pull complete
f4cac829c077: Pull complete
d4a42ebf3983: Pull complete
Digest: sha256:c75e215751eb741878f34fd841d910a018eb1bf2d17a9ffe731f24ab2bf3cca2
Status: Downloaded newer image for ghcr.io/open-webui/open-webui:main
1ed2b1cdd145cb794c140a74245544b19fef8fd4efa9002b2a3d0a96ac0f62db

C:\Users\60578>docker ps
CONTAINER ID   IMAGE                                COMMAND                  CREATED        STATUS        PORTS
NAMES
1ed2b1cdd145   ghcr.io/open-webui/open-webui:main  "bash start.sh"         19 seconds ago Up 17 seconds  0.0.0.0:3000->808
0/tcp         open-webui

C:\Users\60578>
```

CSDN @流浪的小新

4.确定运行

访问地址: <http://localhost:3000/>

5.注册

刚开始需要注册管理员

Amamg 78635585@qq.com

6.离线部署（暂时没有尝试）

若要离线部署,

1.获取IMAGE ID : 3d935ad7dc43

Docker images

2.docker save -o open-webui.tar 3d935ad7dc43

3.在离线的机器上装载镜像

docker load -i open-webui.tar

4.启动容器

docker run -d -p 3000:8080 --add-host=host.docker.internal:host-gateway -v open-webui:/app/backend/data --name open-webui --restart always ghcr.io/open-webui/open-webui:main

5.访问地址

<http://localhost:3000/>

需要注意的问题, open-webui使用GPU时docker启动容器的代码可能不一样

三、使用AnythingLLM搭建本地知识库

如果想要对知识库进行更加灵活的掌控, 我们需要一个额外的软件: AnythingLLM, 这个软件包含了所有Open WebUI的能力, 并且额外支持了以下能力

- 选择文本嵌入模型
- 选择向量数据库

[Download AnythingLLM for Desktop](#)

配置

1.选择大模型（ollama）

LLM 偏好

AnythingLLM 可以与多家 LLM 提供商合作。这将是处理聊天的服务。

 Search LLM providers



HuggingFace

Access 150,000+ open-source LLMs and the world's AI community



Ollama

Run LLMs locally on your own machine.



Novita AI

Reliable, Scalable, and Cost-Effective for LLMs from Novita AI



LM Studio

Discover, download, and run thousands of cutting edge LLMs in a few clicks.



Local AI

Run LLMs locally on your own machine.

Ollama Model

qwen3:8b

▼

Choose the Ollama model you want to use for your conversations.

Max Tokens

4096

Maximum number of tokens for context and response.

Show advanced settings ▼

Ollama Model

qwen3:8b



Choose the Ollama model you want to use for your conversations.

Max tokens

4096

Maximum number of tokens for context and response.

Hide advanced settings ^

Ollama Base URL

http://127.0.0.1:114

Enter the URL where Ollama is running.

Performance Mode

Base (Default)



Choose the performance mode for the Ollama model.

Ollama Keep Alive

5 minutes



Choose how long Ollama should keep your model in memory before unloading. [Learn more →](#)

Auth Token

Enter a **Bearer** Auth Token for interacting with your Ollama server. Used **only** if running Ollama behind an authentication server.

Ollama Auth Token

2.选择文本嵌入模型和向量数据库（默认）

数据处理与隐私

我们致力于在涉及你的个人数据时提供透明和控制。

LLM Selection



Ollama

- Your model and chats are only accessible on the machine running Ollama models

Embedding Preference



AnythingLLM Embedder

- Your document text is embedded privately on this instance of AnythingLLM



Vector Database



LanceDB

- Your vectors and document text are stored privately on this instance of AnythingLLM

这些设置可以随时在设置中重新配置。

3.创建工作区并嵌入文档

创建自己的工作区→上传文档在工作区进行文本嵌入
点击上传文件→点击后移动到工作区→保存并嵌入



4.选择对话模式

anythingllm提供了两种对话模式，chat（训练数据+上传的文档）和query模式（仅依赖于文件） 进入工作区界面，点击右边的设置按钮→聊天设置（聊天和查询）



其他


1.本地nvm配置

<https://github.com/coreybutler/nvm-windows/releases>

2. 相关知识（不一定对，引用的）

RAG技术

Open-webui一般有两种使用方式，一种是直接对话，一种是RAG能力，可以让模型根据文档的内容回答问题（用户输入口上传文件）



文档加载 (Document Loading) :

从多种不同来源加载文档。LangChain提供了100多种不同的文档加载器，包括PDF在内的非结构化的数据、SQL在内的结构化的数据，以及Python、Java之类的代码等

文本加载器 (Document Loaders) 就是将用户提供的文本加载到内存中，便于进行后续的处理

· 文本分割 (Splitting) :

文本分割器 (Text Splitters) 把Documents 切分为指定大小的块，我把它们称为“文档块”或者“文档片”文本切割通常有以下几个原因

- 为了更好的进行文本嵌入以及向量数据库的存储

- 通常大语言模型都有上下文的限制，如果不进行切割，文本在传递给大模型的时候可能超出上下文限制导致大模型随机丢失信息

文本切割器的工作流程

- 将文本切割成小的，语义上有意义的块（通常是句子）

- 开始将这些小块组成一个较大的块，直到达到某个块的大小（这个会通过某种函数测量）

- 一旦达到该大小，就将该块作为自己的文本片段，并开始创建一个新的文本块，同时保留一些重叠（以保持块之间的上下文）。

· 存储 (Storage) :

存储涉及到两个环节，分别是：

将切分好的文档块进行嵌入 (Embedding) 转换成向量的形式

将Embedding后的向量数据存储到向量数据库

· 检索 (Retrieval) :

一旦数据进入向量数据库，我们仍然需要将数据检索出来，我们会通过某种检索算法找到与输入问题相似的嵌入片，这里主要利用了大模型的能力

· Output (输出) :

把问题以及检索出来的嵌入片一起提交给LLM，LLM会通过问题和检索出来的提示一起来生成更加合理的答案

涉及到：

文本嵌入模型 (Text Embedding models)

文本嵌入模型是用来将文本转换成数值向量的工具，这些向量能够捕捉文本的语义信息，使得相似的文本在向量空间中彼此接近。这对于各种自然语言处理任务，如文本相似性比较、聚类 and 检索等，都是非常有用的。下面是一段对嵌入的解释

词嵌入 (Word Embedding) 是自然语言处理和机器学习中的一个概念，它将文字或词语转换为一系列数字，通常是一个向量。简单地说，词嵌入就是一个为每个词分配的数字列表。这些数字不是随机的，而是捕获了这个词的含义和它在文本中的上下文。因此，语义上相似或相关的词在这个数字空间中会比较接近。

举个例子，通过某种词嵌入技术，我们可能会得到：

“国王” -> [1.2, 0.5, 3.1, ...]

“皇帝” -> [1.3, 0.6, 2.9, ...]

“苹果” -> [0.9, -1.2, 0.3, ...]

从这些向量中，我们可以看到“国王”和“皇帝”这两个词的向量在某种程度上是相似的，而与“苹果”这个词

相比，它们的向量则相差很大，因为这两个概念在语义上是不同的。

词嵌入的优点是，它提供了一种将文本数据转化为计算机可以理解和处理的形式，同时保留了词语之间的语义关系。这在许多自然语言处理任务中都是非常有用的，比如文本分类、机器翻译和情感分析等。

向量数据库 (Vector Stores)

向量存储 (Vector stores) 是用于存储和检索文本嵌入向量的工具。这些向量是文本数据的数值表示，它们使得计算机能够理解和处理自然语言。向量存储对于支持复杂的搜索和检索任务至关重要，尤其是在处理大量文本数据时。

向量存储的主要功能包括：

高效地存储大量的文本向量

快速检索与给定向量最相似的文本向量

支持复杂的查询操作，如范围搜索和最近邻搜索

3. 参考教程

[【AI】Ollama+OpenWebUI+llama3本地部署保姆级教程，没有连接互联网一样可以使用AI大模型!!! ollama webui-CSDN博客](#)

[只需三步，手把手教你部署本地大模型以及搭建个人知识库!!! - 知乎](#)