

- 1.修改虚拟最大内存映射区域数
- 2.克隆存储库
- 3.启动
- 4.检查服务器启动状态
- 5.部署ollama模型
 - (1) 找到ollama模型并保证路径可访问
 - (2) 添加ollama
- 6.设置默认模型
- 7.创建知识库并上传本地文件
- 8.基于本地知识库开启对话
- bug及解决
 - 1.使用docker启动ragflow的时候报错
 - 2.端口被占用
 - 3.配置ollama时报错
- 参考内容

1.修改虚拟最大内存映射区域数

vm.max_map_count此值设置进程可以具有的最大内存映射区域数。其默认值为 65530。虽然大多数应用程序需要的映射少于 1000 个，但减小此值可能会导致异常行为，并且当进程达到限制时，系统将引发内存不足错误。

本机使用的是docker desktop对的wsl2后端，参考官网说明，使用以下代码修改，但是这种修改是每次重启都需要修改一次。

```
wsl -d docker-desktop -u root
sysctl -w vm.max_map_count=262144
```

2.克隆存储库

将ragflow的github代码克隆到本地

```
git clone https://github.com/infiniflow/ragflow.git
cd ragflow/docker
git checkout -f v0.19.1
```

要下载不同于的 RAGFlow 版本，在使用启动服务器之前在 docker/.env 中相应地更新变量。

3.启动

有两种方式，一个是CPU一个是GPU方式，我选用GPU的方式启动

```
# 使用CPU执行嵌入和deepdoc任务：
$ docker compose -f docker-compose.yml up -d

# 使用GPU加速执行嵌入和deepdoc任务：
# docker compose -f docker-compose-gpu.yml up -d
```

启动的过程中发现报错，发现本机的80端口被占用了，因此将docker-compose-gpu.yml文件中的ports端口映射更改为8080:80，参考bug及解决的第3点

4.检查服务器启动状态

```
docker logs -f ragflow-server
```

进入<http://localhost:8080/>，看到登录界面即代表本地部署ragflow完成，**在首页完成注册**。

5.部署ollama模型

RAGFlow 是一个 RAG 引擎，需要与 LLM 合作才能提供接地气、**无幻觉**的问答功能。使用 Ollama、Xinference 或其他框架部署和运行本地模型。具体还可以参考官网教程：[Deploy local models | RAGFlow](#)

(1) 找到ollama模型并保证路径可访问

同一台主机，如果 RAGFlow 是从源代码启动的，并且 Ollama 与 RAGFlow 在同一台主机上运行，请检查是否可以从 RAGFlow 的主机访问 Ollama，**打开cmd，输入下述代码**

```
curl http://localhost:11434/
```

打印出如下结果代表访问成功
> ollama is running


(2) 添加ollama

前提：**本地ollama部署并启动**，从官网下载相对应的模型到本地：

```
ollama pull deepseek-r1:7b
ollama pull shaw/dmeta-embedding-zh
ollama pull qwen3:8b
ollama ls #查看已经下载的模型
```

```
Success
(base) PS C:\Users\Administrator> ollama ls
NAME                                ID                                SIZE    MODIFIED
shaw/dmeta-embedding-zh:latest      41783961c26d                     408 MB  10 seconds ago
bge-m3:latest                       790764642607                     1.2 GB  13 minutes ago
qw-15:latest                        c56de87b5414                     3.7 GB  5 days ago
qwen3:8b                             e4b5fd7f8af0                     5.2 GB  5 weeks ago
deepseek-r1:7b                      0a8c26691023                     4.7 GB  5 weeks ago
(base) PS C:\Users\Administrator>
```

登录账号后点击个人头像，进入配置界面



在待添加的模型下方找到ollama，点击添加模型，配置参数如下：

添加 LLM

* 模型类型

chat

* 模型名称

deepseek-r1:7b

* 基础 Url

http://localhost:11434

API-Key

请输入api key（如果是本地部署的模型，请忽略它）

* 最大token数

128

是否支持 Vision

☒

如何集成 Ollama

取消

确定

tips: 如果配置不成功, 点击模型类型为chat的时候报错: **Fail to access embedding model(shaw/dmeta-embedding-zh:latest).[Errno 111] Connection refused**

在用户变量中添加 OLLAMA_HOST 0.0.0.0:11434
并在模型url中配置为 host.docker.internal:11434

添加 LLM

* 模型类型

chat

* 模型名称

deepseek-r1:7b

* 基础 Url

host.docker.internal:11434

API-Key

请输入api key (如果是本地部署的模型, 请忽略它)

* 最大token数

512

是否支持 Vision


☐

如何集成 Ollama


取消

确定

配置好后如图所示:



6.设置默认模型



设置默认模型

聊天模型 ?

deepseek-r1:7b

▼

嵌入模型 ?

shaw/dmeta-embedding-zh:latest

▼

Img2txt模型 ?

qwen3:8b

▼

Speech2txt模型 ?

▼

Rerank模型 ?

▼

TTS模型 ?



▼

取消

确定

7.创建知识库并上传本地文件


点击知识库→创建知识库→输入知识库名称→新增本地文件



等待解析状态为成功,

8.基于本地知识库开启对话

聊天→新建助理→设置→开始聊天





聊天配置

为你的知识库配置专属聊天助手! 

×

助理设置

提示引擎

模型设置

* 助理姓名

青皮钢助手

助理描述

青皮钢数据集

助理头像

+

上传

空回复 

设置开场白 

你好! 我是你的助理, 有什么可以帮到你的吗?

显示引文 

☒

关键词分析 

☐

文本转语音 

☐

Tavily API Key 

请输入你的 Tavily API Key



[如何获取?](#)

知识库 

 青皮钢 ×

▼

设置完成后就可以开启对话了

bug及解决

1.使用docker启动ragflow的时候报错

Error response from daemon: Get "<https://registry-1.docker.io/v2/>": context deadline exceeded

解决方案，修改docker镜像：

```
{
  "builder": {
    "gc": {
      "defaultKeepStorage": "20GB",
      "enabled": true
    }
  },
  "experimental": false,
  "features": {
    "buildkit": true
  },
  "registry-mirrors": [
    "https://82m9ar63.mirror.aliyuncs.com",
    "http://hub-mirror.c.163.com",
    "https://docker.mirrors.ustc.edu.cn",
    "https://docker-cf.registry.cyou",
    "https://dockercf.jsdelivr.fyi",
    "https://docker.jsdelivr.fyi",
    "https://dockertest.jsdelivr.fyi",
    "https://mirror.aliyuncs.com",
    "https://dockerproxy.com",
    "https://mirror.baidubce.com",
    "https://docker.m.daocloud.io",
    "https://docker.nju.edu.cn",
    "https://docker.mirrors.sjtug.sjtu.edu.cn",
    "https://docker.mirrors.ustc.edu.cn",
    "https://mirror.iscas.ac.cn",
    "https://docker.rainbond.cc",
    "https://do.nark.eu.org",
    "https://dc.j8.work",
    "https://dockerproxy.com",
    "https://gst6rzl9.mirror.aliyuncs.com",
    "https://registry.docker-cn.com",
    "http://hub-mirror.c.163.com",
    "http://mirrors.ustc.edu.cn/",
    "https://mirrors.tuna.tsinghua.edu.cn/",
    "http://mirrors.sohu.com/"
  ]
}
```

2.端口被占用

Error response from daemon: Ports are not available: exposing port TCP 0.0.0.0:80 -> 127.0.0.1:0: listen tcp 0.0.0.0:80: bind: An attempt was made to access a socket in a way forbidden by its access permissions.

查看端口

```
netstat -ano | findstr :80
```

将docker-compose-gpu.yml文件中的ports端口映射更改为8080:80

3.配置ollama时报错

Fail to access embedding model(shaw/dmeta-embedding-zh:latest).[Errno 111] Connection refused

[RAGflow+Ollama本地部署填坑 - 知乎](#)

在用户变量中添加 OLLAMA_HOST 0.0.0.0:11434;
并在模型url中配置为 host.docker.internal:11434;

参考内容

1. [Get started | RAGFlow](#)
2. [【万字详解】手把手带你一步步搭建RAGFlow（超干货） ragflow安装教程-CSDN博客](#)
3. [一文读懂RAGFlow：从 0 到 1教你搭建RAG知识库-CSDN博客](#)